#### Réseaux de neurones convolutionnels!!

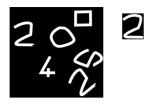
Agissent comme des détecteurs de motifs!

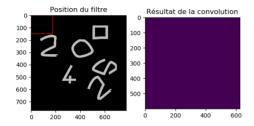
#### Réseaux de neurones convolutionnels!!

Agissent comme des détecteurs de motifs!

Voyons cela sur une forme simple...

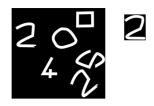
#### À quoi ressemblera la convolution de cette image avec ce patch?

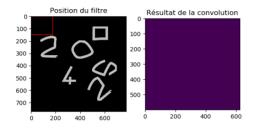




np.unravel\_index(np.argmax(result),result.shape)
Out[10]: (174, 68) # position du chiffre 2 sur l'image.

#### À quoi ressemblera la convolution de cette image avec ce patch?

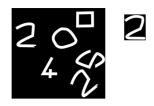


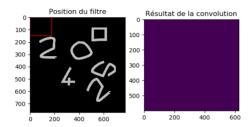


np.unravel\_index(np.argmax(result),result.shape)
Out[10]: (174, 68) # position du chiffre 2 sur l'image.

• La convolution détecte le motif quelque soit la translation

#### À quoi ressemblera la convolution de cette image avec ce patch?



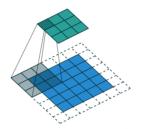


np.unravel\_index(np.argmax(result),result.shape)
Out[10]: (174, 68) # position du chiffre 2 sur l'image.

- La convolution détecte le motif quelque soit la translation
- Évidemment, en pratique, les filtres sont appris, et sont beaucoup plus abstraits.

## Transposed convolution

En deep learning, le pas et le pooling réduisent la taille de l'image.



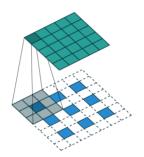
Parfois, nous voulons obtenir l'effet inverse,

- Segmentation d'image
- Visualisation et interpetation

mais comment?

# Transposed convolution (parfois abusivement appelé Déconvolution)

Insertion de zéros et convolution classique:



#### Soient

- $x=[x_1\dots x_7]$  un signal 1D,
- $w=[w_1,w_2,w_3]$  un filtre,
- $y=[y_1,y_2,y_3]$  la convolution  $(x\star w)$  avec un pas de 2.

Cette opération peut s'écrire sous la forme:

$$egin{pmatrix} y_1 \ y_2 \ y_3 \end{pmatrix} = egin{pmatrix} w_1 & w_2 & w_3 & 0 & \dots & 0 \ 0 & 0 & w_1 & w_2 & w_3 & & \dots \ 0 & \dots & & & w_1 & w_2 & w_3 \end{pmatrix} egin{pmatrix} x_1 \ x_2 \ dots \ x_8 \end{pmatrix}$$

Ou de manière plus compacte: y = Wx

Étant donné que la convolution s'écrit

$$y = Wx$$

Cherchons à déconvoluer en calculant:

$$W^{-1}y$$

Étant donné que la convolution s'écrit

$$y = Wx$$

Cherchons à déconvoluer en calculant:

$$W^{-1}y$$

Faisons l'hypothèse que W est orthonormale, nous avons alors:

$$W^{-1}=W^T$$

Étant donné que la convolution s'écrit

$$y = Wx$$

Cherchons à déconvoluer en calculant:

$$W^{-1}y$$

Faisons l'hypothèse que  ${\cal W}$  est orthonormale, nous avons alors:

$$W^{-1}=W^T$$

Un exemple pour lequel cette hypthèse est vraie:

$$W = [-1, 0, 0, 1]$$

Dans la vraie vie, c'est rare.

Sous condition d'othonormalité, le signal déconvolué  $\hat{x}$  s'écrit:

$$\hat{x} = W^T y$$
  $\begin{pmatrix} x_1 & 0 & 0 \ w_2 & 0 & dots \ w_3 & w_1 & dots \ x_8 \end{pmatrix} = egin{pmatrix} w_1 & 0 & 0 \ w_2 & 0 & dots \ w_3 & w_1 \ 0 & w_2 \ 0 & 0 & w_3 \end{pmatrix} egin{pmatrix} y_1 \ y_2 \ y_3 \end{pmatrix}$ 

Réarrangement des termes: La déconvolution est une convolution!

$$egin{pmatrix} x_1 \ x_2 \ \vdots \ x_8 \end{pmatrix} = egin{pmatrix} w_3 & w_2 & w_1 & 0 & \dots & 0 \ 0 & w_3 & w_2 & w_1 & & \vdots \ \vdots & 0 & w_3 & w_2 & w_1 & & \ & & \dots & & & \ 0 & & & w_3 & w_2 & w_1 \end{pmatrix} egin{pmatrix} 0 \ 0 \ y_2 \ 0 \ 0 \ y_3 \ 0 \ 0 \end{pmatrix}$$

# À retenir de cette dernière partie

- L'augmentation de la résolution peut être réalisée par une convolution en insérant des zéros
- Sous certaines hypothèses fortes, cela correspond à une déconvolution
- En pratique, ce n'est pas le cas:
- => Permet d'obtenir une visualisation (voir prochain cours sur l'inteprétation des réseaux )
- => Effet négligeable quand les filtres sont appris: Segmentation d'image.

Source: Lecture 7 du cours de deep learning CS320

#### Glossaire

- Padding : ajouter des lignes et des colonnes sur l'extérieur de l'image
- scaling : réduire / augmenter la taille de l'image
- shearing : scaling vertical et horyzontal de différentes amplitudes
- cropping : extraire une partie de l'image.
- stride: pas de convolution

## Lab: Manipulation basiques et convolutions

Ouvrir le fichier: TPconvolutions.ipynb